BEYOU Matthieu
LEDRU Mathieu

EIT

MOTEUR DE REQUETES

Installation du programme

Ce projet a été développé sous Windows, et n'est malheureusement pas portable (les appels systèmes au Tree-tager ainsi que les séparateurs de fichiers sont codés en dur dans les scripts). Il faut donc l'installer sous Windows.

Décompresser l'archive dans le dossier devant contenir le projet.

Le Tree-tager utilisé est fourni dans avec les sources, se reporter au fichier README présent dans le dossier concerné. ***Ne pas oublier de configurer les variables d'environnement et les chemins d'accès dans les batchs comme indiqué pour que l'appel au Tree-tager soit valable depuis le répertoire Scripts du projet***.

Décompresser l'archive et configurer le Tree-tager comme indiqué dans le fichier README doit normalement suffir à rendre les scripts fonctionnels.

N'hésitez pas à nous contacter si vous éprouvez des difficultés à l'installer.

Indexation du corpus

Pour indexer les lemmes constituant le cospur pondérés par leur tfidf, une première passe sur tout le corpus est effectuée pour calculer les idf de chaque lemme (puisqu'il faut connaître le nombre de document dans lequel le lemme apaprait) et les stocker dans une table de hashage.

Ensuite, une seconde passe sur tout le corpus calcule le tfidf de chaque lemme grace à la table de hashage précédemment remplie et enregistre dans les fichiers d'index une ligne constituée du nom du fichier qui contient le lemme, une tabulation et la valeur du tfidf.

Chaque lemme a son propre fichier d'index. Cette solution a été retenue car jugée plus pratique qu'un seul fichier très volumineux. En revanche, certains lemmes ne peuvent pas être indexés de cette manière : ceux qui contiennent des caractères interdits dans les noms de fichiers.

L'indexation du corpus étant un processus extrêmement long, pour des raisons de temps les scripts ont été testés sur une version réduite du corpus de 3 thèmes contenant chacun 50 documents. Tout fonctionnait très bien sur cette version du corpus. En revanche, lors du test sur le corpus entier le processus s'est figé sur un fichier pour une raison indéterminée (le fichier incriminé est Cinema\0085.txt). La raison de ce comportement n'ayant pas été trouvée, ce problème n'a pas pu être corrigé.

Le corpus allégé de test au format texte et son index sont fourni dans les dossiers CorpusLightTxt et IndexLight.

Pour appeler le script d'indexation du corpus, utiliser la commande suivante depuis le sous-répertoire Scripts : index.pl <CORPUS>

CORPUS est le chemin du corpus à indexer au format teste. Dans notre cas, utiliser .\CorpusTxt ou ..\CorpusLightTxt pour le corpus allégé.

Exécution d'une requete

Un second script Perl exécute une requête entrée par l'utilisateur. Pour des raisons de manque de temps le modèle le plus simple a été implémenté : le modèle booléen. Ce modèle renvoit les documents contenant exactement les termes demandés à l'aide des opérateurs booléens OR et AND.

Il est à noter que la syntaxe est importante : les opérateurs booléens doivent être entrés en majuscules.

Le script commence par vérifier que la requête est bien formée: vérification du parenthésage et des positions des opérateurs booléens (pas 2 lemmes consécutifs ni 2 opérateurs booléens consécutifs).

Ensuite l'algorithme de résolution de la requête est au final très simple :

Soit la requête commence par un lemme simple

Dans ce cas => récupérer dans un tableau les noms des fichiers contenant le lemme

Sinon la requête commence par une sous-requête (expression parenthésée)

Dans ce cas => exécuter la sous-requête et récupérer son résultat dans un tableau

Ensuite si la requête est de la forme « partie_1 opérateur partie_2 »

Récupérer l'opérateur booléen

Récupérer le résultat de la partie 2 de la requête de la même façon que la partie 1

Si l'opérateur est AND

Retourner l'intersection des 2 tableaux

Si l'opérateur est OR

Retourner l'union des 2 tableaux

Le résultat final de la requête est stocké dans un fichier nommé *resultatsRequete.txt* et placé dans le répertoire du projet.

Remarque : l'écriture de la requête dans un fichier est nécessaire afin de pouvoir la lemmatiser, le Tree-tager installé ne travaillant que sur des fichiers.

L'utilisation d'un script Perl offre la possibilité d'exécuter les requêtes directement en ligne de commande sans passer par l'interface graphique, et donc pourquoi pas de le faire depuis un autre programme.

La syntaxe est la suivante depuis le sous-répertoire Scripts : requete.pl <INDEX> <REQUETE>

INDEX est le chemin au répertoire contenant l'index à utiliser, dans notre cas : ..\Index ou ..\IndexLight pour travailler sur le corpus allégé.

REQUETE est la requête à exécuter. Penser à la protéger avec des guillements afin de bien passer la requête comme une seule chaine de caractères.

Interface d'entrée des requêtes

Une interface graphique simple a été dévelopée en Java afin de pouvoir saisir des requête de manière plus conviviale que par la ligne de commande.

Néanmoins, faute de temps elle n'a pas pu être terminée à temps (à cause de problèmes concernant le lancement des scripts Perl depuis le programme Java qui n'ont pu être résolus dans les temps).

En revanche, il est tout à fait possible d'exécuter une requête en ligne de commande et de visualiser le résultat à la main dans le fichier *resultatsRequete.txt*.

Le code de l'interface a toutefois été placé dans le dossier MoteurRequete.

Son fonctionnement prévu était de taper la requête dans le champ de saisie, et cliquer sur le bouton « Exécuter » pour exécuter la requête et afficher dans la liste les noms des fichiers trouvés. Ensuite, cliquer sur les éléments de cette liste devait ouvrir le fichier sélectionné.